



VISÃO COMPUTACIONAL

RESIDÊNCIA EM TIC43

TAREFA

Análise global, local e de textura em mini dataset próprio

Unidade 03 | Capítulo 02

Prof.: Rafael Carmo



Unidade 03

Capítulo 02

Objetivo

Ao final da atividade, o estudante deverá ser capaz de:

- utilizar um mini dataset próprio para análise em Visão Computacional;
- gerar e interpretar histogramas de intensidade e cor;
- calcular e interpretar média, variância, desvio padrão e entropia;
- detectar pontos de interesse e extrair descritores locais;
- realizar matching entre imagens e discutir a qualidade das correspondências;
- extrair características de textura com GLCM e LBP;
- comparar, de forma crítica, descritores globais, locais e de textura;
- justificar qual representação é mais adequada para o seu dataset.

Enunciado:

Esta atividade dá continuidade direta ao mini dataset construído anteriormente. Em vez de coletar novas imagens, a proposta agora é analisar tecnicamente o próprio conjunto já criado, observando como diferentes representações da imagem ajudam – ou falham – na distinção entre classes.

Ao longo da tarefa, você deverá sempre responder à pergunta:

O que este descritor preserva e o que ele perde?

Regras gerais

- Utilize o mini dataset criado anteriormente, com 2 classes e 10 imagens originais no total.
- A resposta deve ser feita em Google Colab ou notebook Jupyter, com código + interpretação em markdown.
- Não basta executar o código: é obrigatório interpretar os resultados.
- Sempre que possível, compare o efeito de:
 - iluminação;
 - distância/ângulo;
 - resolução;
 - compressão/formato;
 - textura;
 - cor predominante.
- Se suas classes forem mais distinguíveis por cor, isso deve aparecer na análise dos histogramas.



- Se suas classes forem mais distinguíveis por forma/estrutura, isso deve aparecer na análise local com keypoints, descritores e matching.
- Se suas classes não forem fortemente texturais, a etapa de textura continua obrigatória, mas a conclusão pode mostrar que GLCM/LBP não foram os descritores mais discriminativos para o seu caso.

Você deverá reutilizar o mini dataset construído na atividade anterior e investigar como diferentes estratégias de representação da imagem se comportam diante de variações reais de captura.

A proposta é analisar o seu conjunto de imagens em três níveis complementares:

1. Nível global: histogramas e estatísticas da imagem;
2. Nível local: pontos de interesse, descritores ORB e correspondência entre imagens;
3. Nível de textura: descritores baseados em relações espaciais e padrões locais, como GLCM e LBP.

Ao final, você deverá produzir uma conclusão técnica respondendo:

Qual representação foi mais adequada para o seu mini dataset e por quê?

Instruções:

Parte 1 – Preparação do dataset e hipótese inicial

1. Reapresente as duas classes do seu mini dataset.
2. Mostre a estrutura de pastas utilizada.
3. Exiba ao menos 2 imagens de cada classe.
4. Registre, em markdown:
 - quais fatores de aquisição podem influenciar a análise;
 - quais diferenças visuais você espera entre as classes;
 - qual descritor você acredita, antes do experimento, que será mais útil:
 - histograma/estatística;
 - descritores locais;
 - textura.

Entrega mínima desta parte

- árvore de pastas;
- breve descrição das classes;
- hipótese inicial.

Parte 2 - Análise global: histogramas e estatística

Utilize as 10 imagens originais do dataset.





Estatística global

Para cada imagem, calcule:

- média;
- variância;
- desvio padrão;
- entropia.

Monte uma tabela-resumo com os valores das 10 imagens.

22 Histogramas

Escolha ao menos:

- 2 imagens de cada classe para histogramas de intensidade;
- 2 imagens de cada classe para histogramas de cor, em RGB ou HSV.

Responda em markdown:

- onde a imagem concentra mais pixels: tons escuros, médios ou claros?
- existe canal de cor dominante?
- as imagens da mesma classe apresentam comportamento parecido?
- o histograma ajudou a separar as classes?

23 Relação com a tarefa anterior

Escolha, para 1 imagem de cada classe, pelo menos uma versão derivada produzida anteriormente, por exemplo:

- resolução reduzida;
- quantização;
- JPEG com compressão;
- PNG.

Compare com a original e discuta:

- o histograma mudou muito?
- a entropia caiu ou aumentou?
- houve perda perceptível de informação útil?

Entrega mínima desta parte

- 1 tabela com estatísticas das 10 imagens;
- histogramas comentados;
- comparação entre original e versão derivada de cada classe.



Parte 3 - Análise local: pontos de interesse, descritores e matching

3.1 Pontos de interesse

Em pelo menos 1 imagem de cada classe:

- detecte cantos com Shi-Tomasi.

Em pelo menos 1 imagem adicional:

- detecte blobs com `blob_log` ou, caso isso não seja informativo para o seu dataset, explique tecnicamente por que o método não foi tão útil.

3.2 Descritores locais

Escolha:

- 2 pares de imagens da mesma classe;
- 1 par de imagens de classes diferentes.

Para cada par:

- extraia keypoints e descritores ORB;
- informe a quantidade de keypoints detectados;
- compare visualmente as regiões mais informativas.

3.3 Matching

Utilize BFMatcher com distância adequada aos descritores ORB.

Mostre:

- os melhores matches do par de mesma classe;
- os melhores matches do par de classes diferentes.

Discuta:

- houve mais correspondências úteis entre imagens da mesma classe?
- quantidade de matches significou qualidade?
- iluminação, escala, fundo ou ângulo atrapalharam?

3.4 Teste de robustez

A partir de 1 imagem do seu dataset, gere no notebook uma versão modificada, por exemplo:

- rotação leve;
- redução de contraste;



- borramento leve.

Repita ORB + matching e responda:

- o número de keypoints mudou?
- a qualidade dos matches caiu?
- até que ponto o descritor local se mostrou robusto?

Entrega mínima desta parte

- visualização de cantos e/ou blobs;
- ORB em pares de imagens;
- matching comentado;
- teste de robustez com uma transformação adicional.

Parte 4 - Análise de textura: GLCM e LBP

Seleção das regiões

Escolha, para cada classe:

- 1 imagem inteira ou
- 1 patch/recorte representativo da superfície do objeto.

Se o seu dataset não tiver textura forte, utilize recortes mais representativos e explique essa limitação.

4.2 GLCM

Converta a imagem para tons de cinza e faça uma quantização adequada.

Calcule a GLCM com pelo menos:

- 1 distância;
- 2 ângulos.

Extraia e interprete:

- contrast;
- homogeneity;
- energy;
- correlation.





43 LBP

Calcule o LBP e o histograma normalizado dos padrões.

Discuta:

- o LBP capturou microestruturas visuais úteis?
- as classes ficaram mais separáveis por textura?
- GLCM e LBP trouxeram evidências coerentes entre si?

Entrega mínima desta parte

- tabela com propriedades da GLCM;
- imagem ou mapa LBP;
- histograma LBP;
- interpretação técnica.

Parte 5 - Síntese integradora

Monte uma tabela comparativa final com as colunas:

Tipo de descritor	O que representa	Vantagens	Limitações	Funcionou bem no meu dataset?
-------------------	------------------	-----------	------------	-------------------------------

Os tipos a comparar são:

- histogramas;
- estatística global;
- ORB + matching;
- GLCM;
- LBP.

Finalize com uma conclusão respondendo:

1. Qual descritor foi mais útil no seu dataset?
2. Qual descritor foi menos útil?
3. Em que situações a aquisição influenciou fortemente os resultados?
4. Se você fosse treinar um sistema simples de Visão Computacional com esse dataset, quais características usaria primeiro?

Feedback Automático:





Não há. Deve ser analisada pelo »enEor.
RUBRICA DE AVALIAÇÃO

1. Reuso e organização do mini dataset – 15 pontos

- Excelente (13-15): reutiliza corretamente as 2 classes e as 10 imagens, apresenta organização clara, identifica versões derivadas e contextualiza bem as condições de aquisição.
- Bom (10-12): dataset está organizado, mas com documentação parcial ou pequenas inconsistências.
- Regular (5-9): organização incompleta ou pouco clara.
- Insuficiente (0-4): dataset ausente, incoerente ou desconectado da atividade anterior.

2. Análise global: histogramas e estatística – 25 pontos

- Excelente (22-25): calcula corretamente as métricas, apresenta histogramas relevantes e relaciona os resultados às classes, à iluminação, à resolução e ao formato.
- Bom (17-21): cálculos corretos, com análise adequada, mas superficial.
- Regular (8-16): execução parcial ou interpretação limitada.
- Insuficiente (0-7): métricas ausentes, incorretas ou sem discussão.

3. Análise local: pontos de interesse, ORB e matching – 25 pontos

- Excelente (22-25): mostra pontos de interesse, extrai ORB, realiza matching com comparação consistente entre pares e discute robustez e limitações.
- Bom (17-21): pipeline implementado corretamente, com interpretação parcial.
- Regular (8-16): implementação incompleta ou pouco analisada.
- Insuficiente (0-7): etapa ausente ou conceitualmente incorreta.

4. Análise de textura: GLCM e LBP – 20 pontos

- Excelente (18-20): aplica GLCM e LBP corretamente, interpreta os resultados e reconhece quando textura é ou não é útil no dataset.
- Bom (14-17): aplicação correta, com discussão moderada.
- Regular (7-13): análise parcial ou predominantemente descritiva.
- Insuficiente (0-6): ausência da etapa ou erros graves de aplicação.

5. Síntese técnica e clareza do notebook – 15 pontos

- Excelente (13-15): notebook bem organizado, visualizações claras, boa redação e conclusão técnica consistente.
- Bom (10-12): apresentação adequada, com pequenas falhas de organização ou aprofundamento.
- Regular (5-9): notebook confuso ou com explicações insuficientes.
- Insuficiente (0-4): material desorganizado, incompleto ou difícil de compreender.





VISÃO COMPUTACIONAL

RESIDÊNCIA EM TIC43



VISÃO COMPUTACIONAL
RESIDÊNCIA EM TIC43

Coordenação PPI:



Iniciativa:



Executor:



Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.